



# LECTURE 9 CNN Architectures

2070070 정보경

# CONTENTS

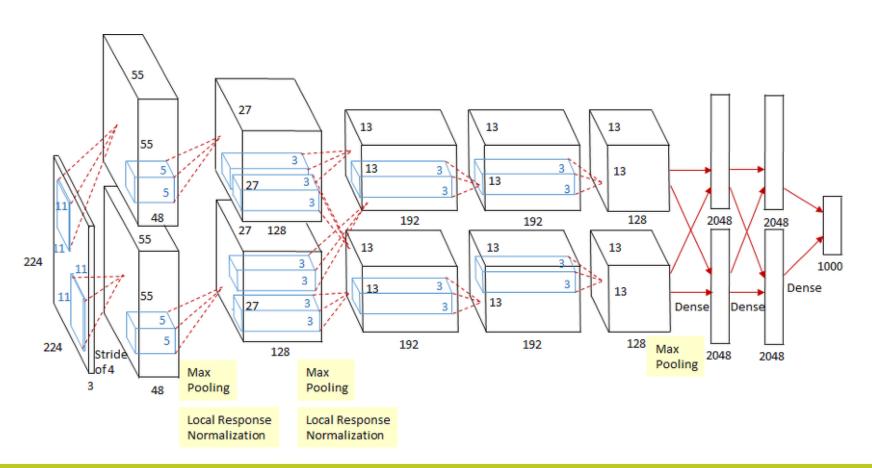
- 1. AlexNet
- 2. VGGNet
- 3. GoogleNet
- 4. ResNet
- 5. Another Net



#### 이화여자대학교 EWHA WOMANS UNIVERSITY

<최초의 Large scale CNN>

#### ✓ Architecture



CONV1 MAX POOL1 NORM1

CONV2 MAX POOL2 NORM2

CONV3 CONV4 CONV5 MAX POOL3

FC6 FC7 FC8



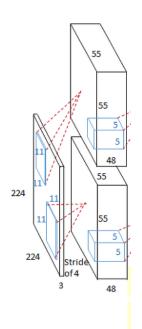


#### <최초의 Large scale CNN>

#### ✓ Architecture

#### Input

Image: 227\*227\*3 (사진과 다름)

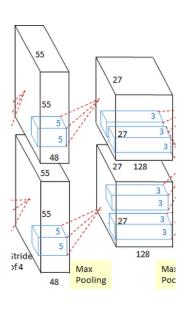


#### 1) CONV1

Filter: 11\*11\*3 96개 / Stride:

Output 크기 (227-11)/4 +1 = 55 55\*55\*96

Parameter 개수 (11\*11\*3)\*96개 (Filter size요소 \* Filter 개수)



#### 2) POOL 1

Filter: 3\*3\*3 96개 / Stride: 2

Output 크기 (55-3)/2 +1 = 27 27\*27\*96

Parameter 개수 0개 (학습의 가중치=Parameter이므로)

#### 이화여자대학교 EWHA WOMANS UNIVERSITY

<최초의 Large scale CNN>

#### ✓ Architecture

```
위와 같은 과정으로 계산할 시,
[227x227x3] Input
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] NORM1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] NORM2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)
```



# 1. Alexnet <최초의 Large scale CNN>



#### ✓ Detail

최초의 ReLU사용

Norm layer 사용 (현재는 잘 쓰이지 않음)

Data Augmentation 많이 사용

Dropout: 0.5

SGD Momentum: 0.9

Learning Rate: 초기: 1e-2 / 1e -10까지 감소

L2 Weight Decay: 5e-4

7개의 CNN ensemble, 성능 향상

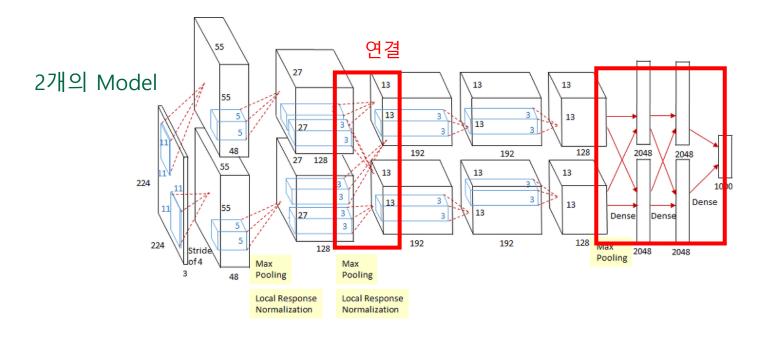


이화여자대학교 EWHA WOMANS UNIVERSITY

<최초의 Large scale CNN>

### ✓ Detail

과거 GTX 580의 memory: 3GB 한 GPU로 모든 데이터 처리가 불가해 2개의 모델로 나 누어 연결하는 방식 사용

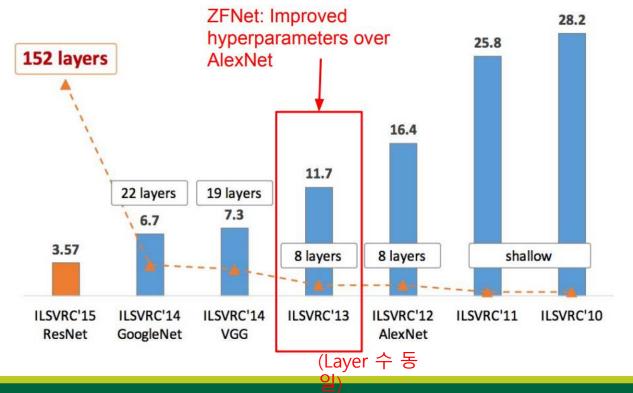


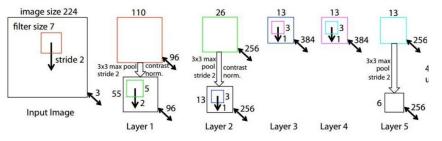
이화여자대학교 EWHA WOMANS UNIVERSITY

<최초의 Large scale CNN>

#### ✓ ZFNet

2013 ImageNet 우승 AlexNet의 Hyperparameter 개선





<AlexNet 개선점>

CONV1 Filter: 7\*7\*3 96개 / Stride: 2 CONV 3, 4, 5 Filter: 512, 1024, 512

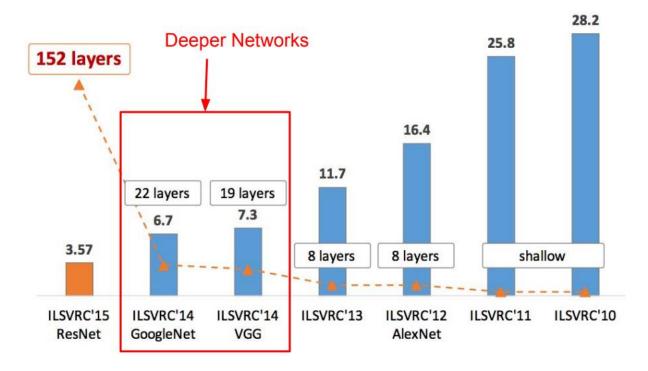


## 



## ✓ Deeper Network

2014-GoogleNet 1위, VGGNet 2위 Deeper Networks 사용



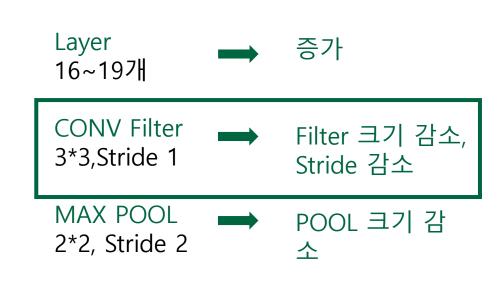
















#### <Filter 크기를 줄인 이유>

3\*3 Filter, Stride 1 이용 시 7\*7 Filter와 동일한 Receptive Field를 얻을 수 있음.

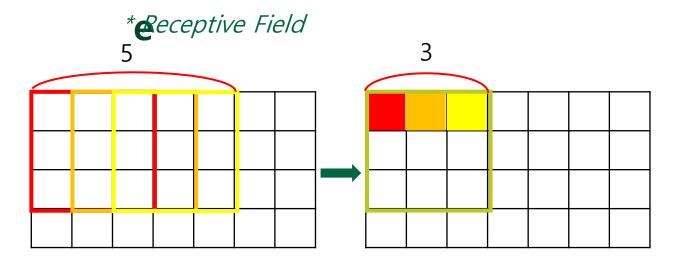
7\*7 Filter보다 Deeper, 비선형적, 적은 Parameter

: 성능이 더 좋음

## 2. VGGNet <Deeper Network 사용>



### ✓ Architectur



- 1) Layer 1의 3\*3 내 요소가 한 칸에 집약
- 2) Layer 2에 3\*3 Filter 적용 시 , Stride 1이므로 Layer 1에서의 5\*5 범위가 파악됨
- 3) Layer 3에 3\*3 Filter 적용 시, Stride 1이므로 Layer 2에서의 5\*5 범위 =Layer1에서의 7\*7 범위가 파악됨

#### \*Parameter

Filter 개수가 3개/ Depth가 d일 때

7\*7 Parameter: 7\*7\*d = 49d

3\*3 Parameter: 3\*3\*3\*d = 27d



## 2. VGGNet



#### <Deeper Network 사용>

### ✓ Architectur

```
(not counting biases)
INPUT: [224x224x3]
                     memory: 224*224*3=150K params: 0
CONV3-64: [224x224x64] memory: 224*224*64=3.2M params: (3*3*3)*64 = 1,728
CONV3-64: [224x224x64] memory: 224*224*64=3.2M params: (3*3*64)*64 = 36,864
POOL2: [112x112x64] memory: 112*112*64=800K params: 0
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*64)*128 = 73,728
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*128)*128 = 147,456
POOL2: [56x56x128] memory: 56*56*128=400K params: 0
CONV3-256: [56x56x256] memory: 56*56*256=800K params: (3*3*128)*256 = 294,912
CONV3-256: [56x56x256] memory: 56*56*256=800K params: (3*3*256)*256 = 589,824
CONV3-256: [56x56x256] memory: 56*56*256=800K params: (3*3*256)*256 = 589,824
POOL2: [28x28x256] memory: 28*28*256=200K params: 0
CONV3-512: [28x28x512] memory: 28*28*512=400K params: (3*3*256)*512 = 1,179,648
CONV3-512: [28x28x512] memory: 28*28*512=400K params: (3*3*512)*512 = 2,359,296
CONV3-512: [28x28x512] memory: 28*28*512=400K params: (3*3*512)*512 = 2,359,296
POOL2: [14x14x512] memory: 14*14*512=100K params: 0
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
POOL2: [7x7x512] memory: 7*7*512=25K params: 0
FC: [1x1x4096] memory: 4096 params: 7*7*512*4096 = 102,760,448
FC: [1x1x4096] memory: 4096 params: 4096*4096 = 16,777,216
FC: [1x1x1000] memory: 1000 params: 4096*1000 = 4,096,000
```

- 1) 초기 CONV에 가장 많은 메모리 사용
- 2) FC에 가장 많은 Parameter 사용 (Dense connection)

TOTAL memory: 24M \* 4 bytes ~= 96MB / image (only forward! ~\*2 for bwd) TOTAL params: 138M parameters







AlexNet (2012 Krizhevsky) 와 유사한 training process

Local Response Normalization (LRN) 사용X

VGG16 (16 Layers), VGG19 (19 Layers)

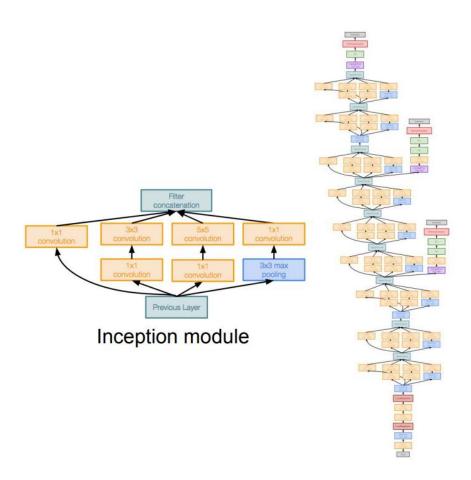
ensemble, 성능 향상

FC7: 특징 잘 추출, 일반화 능력이 좋음



#### 이화여자대학교 EWHA WOMANS UNIVERSITY

#### ✓ Architecture



Layer 22개

Inception Module

FC layer 없음

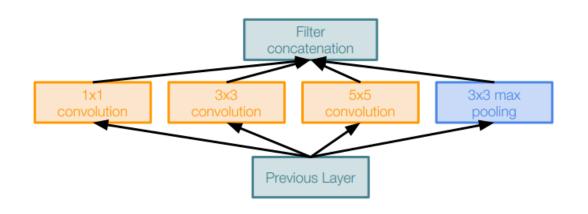
Parameter

5M (VGG: 138M)





\*Waive Inception Module



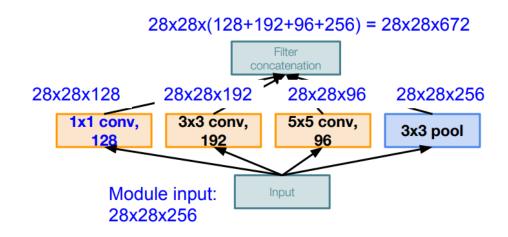
Local Network Topology를 제작, 이를 쌓은 형태

-동일 Input 받는 Filter가 병렬로 존재 -이후 출력을 Depth 방향으로 합하여 1개의 Tensor로 만듦





\* Naive Inception Module



Naïve Inception Module의 단점 <계산량 증가> 동일 Input + 다수의 Layer를 최종적으로 1개의 Tensor로 만듦

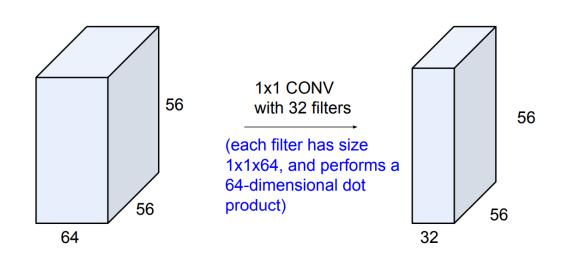
= Depth 매우 크게 증가, 계산량 매우 많아짐





#### \* dottleneck Layer

Naïve module의 계산량 증가에 대한 해법 1\*1 Convolution을 사용하여 병합 전 Layer들을 더 낮은 차원으로 변환



56\*56\*64 에 32개의 1\*1 Filter CONV 처리 (각 요소를 내적하여 Depth만 줄임, 선형 결합)

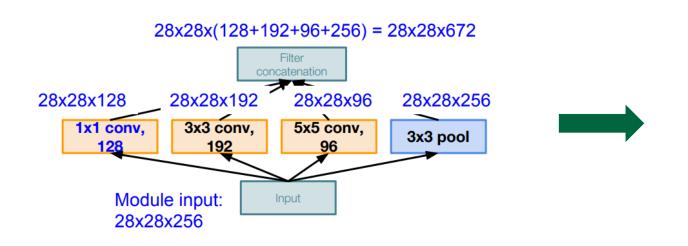
=56\*56\*32의 Output

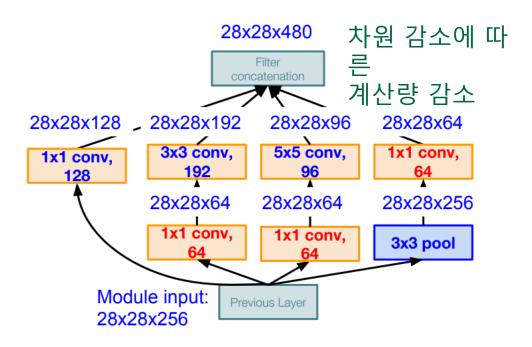
차원 감소





\*enception module with Bottleneck Layer

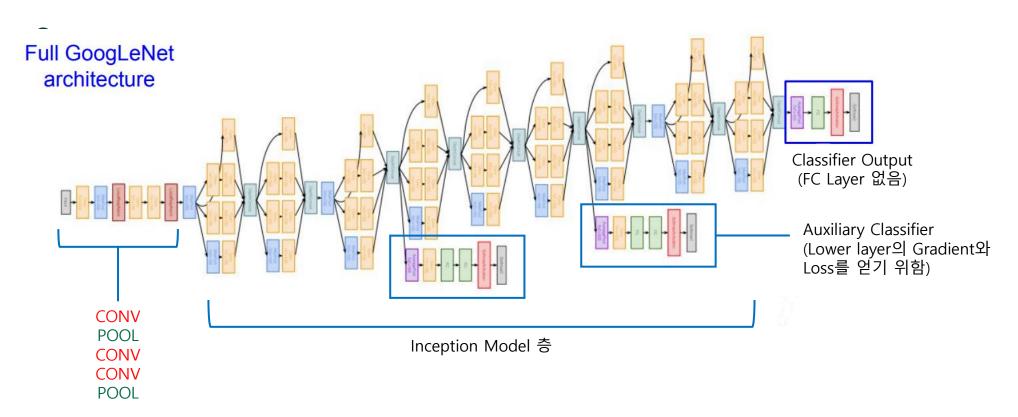




# 3. GoogleNet Inception Module >

#### 이화여자대학교 EWHA WOMANS UNIVERSITY

#### ✓ Architectur



가중치를 가진 Layer: 22개

# 3. GoogleNet <a href="https://www.nception.com/module">nception Module ></a>





Deeper Network / Computation 효율 향상

효율적인 Inception Module

FC Layer 없음

Parameter 적음 (Alexnet보다 12배 적음)

가중치를 가진 Layer: 22개

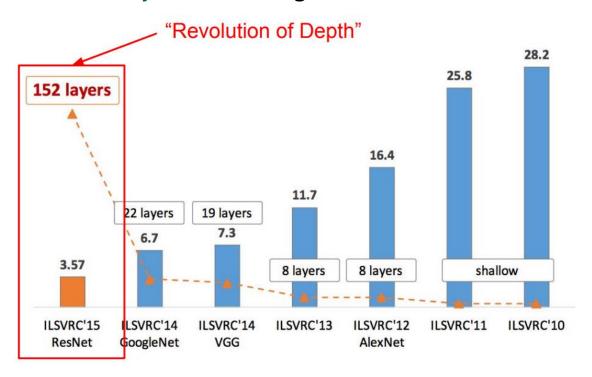
## 4. ResNet

이화여자대학교 EWHA WOMANS UNIVERSITY

<Revolution of Depth>

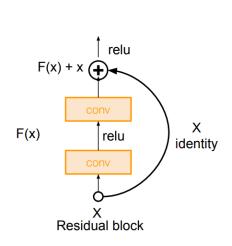
## Revolution of Depth

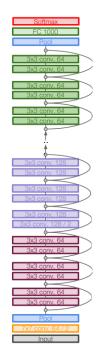
2015-ResNet 1위 152개의 Layer 사용 (GoogleNet: 22개)



Residual Connection을 사용 한

Deep Network





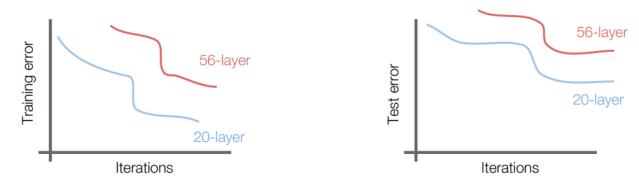




<Revolution of Depth>

## ✓ Hypothesis

일반 CNN의 Layer 수를 늘릴 시 성능의 변화는?



Layer가 많을 때 오히려 성능 감소 Training set에 대해서도 성능 감소, Overfitting이 이유가 아님

→ Optimization이 문제라는 가설 제기 모델이 깊을수록 최적화가 어려울 것이다





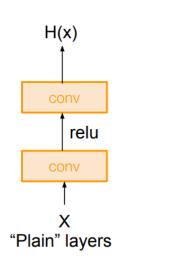
<Revolution of Depth>

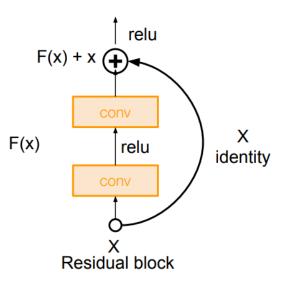
## ✓ Hypothesis

모델이 깊을수록 최적화가 어려울 것이다

많은 Layer에서도 얕은 Model과 같은 성능을 내는 방법

- 1) 얕은 model에서 계산된 가중치를 복사
- 2) identity mapping으로 input data를 바로 Output으로
- = Residual Block





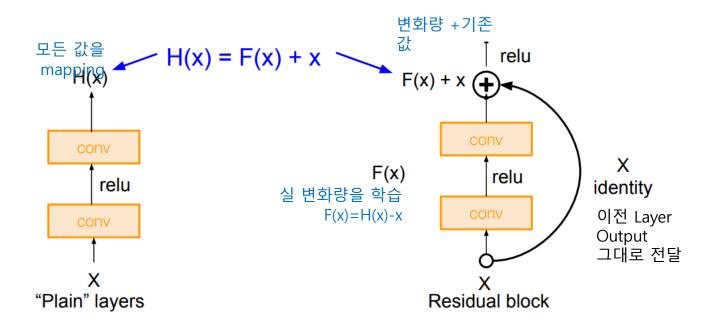


## 4. ResNet

<Revolution of Depth>

#### ✓ Architecture

\*Residual Block



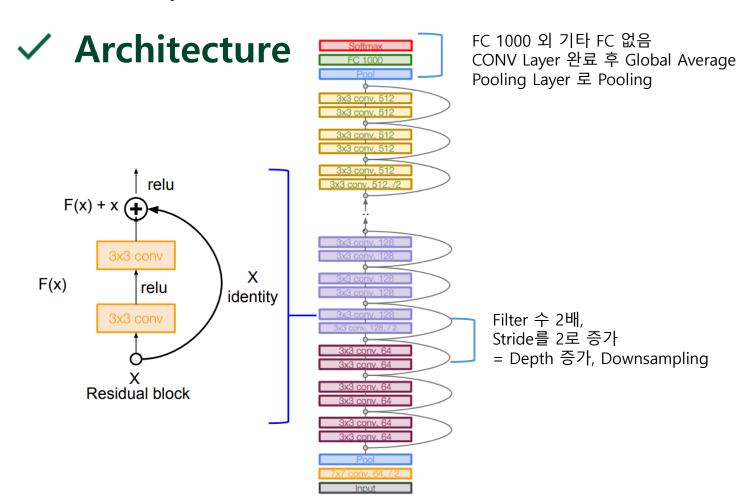
모든 mappin에 대해 fit하는 대신, Residual mappin에 Fit하도록 함 → 관점의 변화

" 기존 값에서 얼마를 변화시키는 것이 효율적인가를 학습"

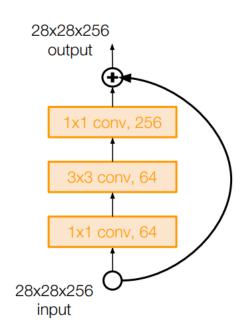


#### 이화여자대학교 EWHA WOMANS UNIVERSITY

<Revolution of Depth>



2개의 3\*3 CONV Layer를 가진 Residual Block을 쌓음



(+) Model Depth가 50 이상일 때만 Bottleneck Layer 사용

# 4. ResNet <a href="Revolution of Depth">Revolution of Depth</a>



### ✓ Detail

모든 CONV Layer 이후 Batch Normalization

Xavier/2 initialization의 초기화 성능이 좋음

SGD Momentum: 0.9

Learning Rate: 초기 0.1

/ Validation Error가 줄지 않는 시점부터 기존

rate/10

Mini-batch의 size: 256

Weight Decay 1e-5

Dropout 사용하지 않음

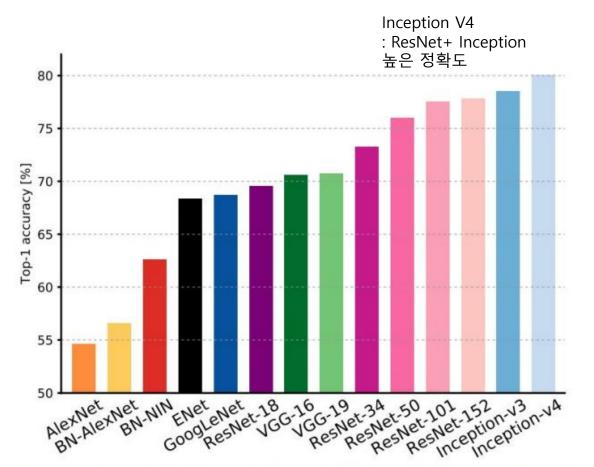
Degrading 없이 Very Deep Network 학습 가능

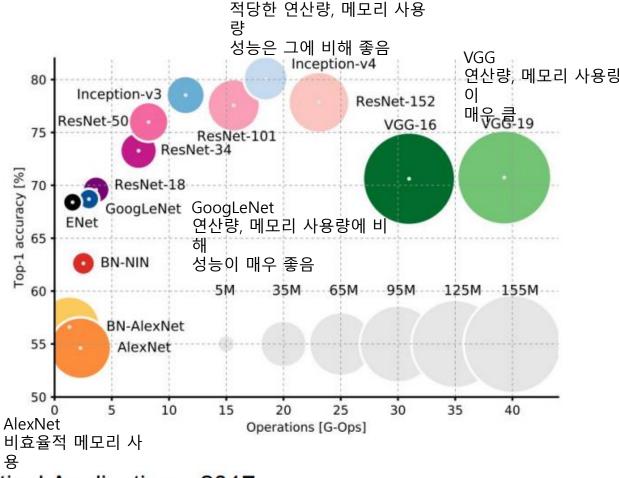
Deeper Network 의 Train error Lowing에 성공 (ResNet에서 얕은 Network의 Error가 더 작은 경우 X)





# **Compare complexity**



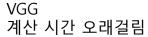


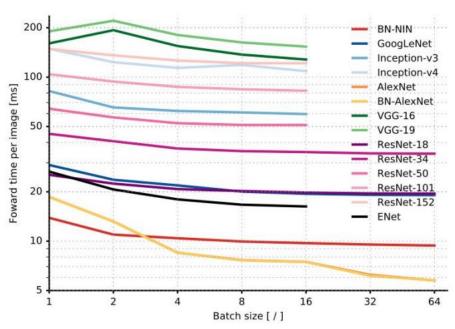
ResNet

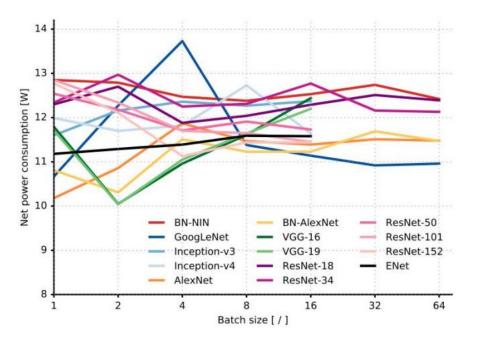
An Analysis of Deep Neural Network Models for Practical Applications, 2017.



# **Compare complexity**





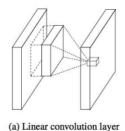


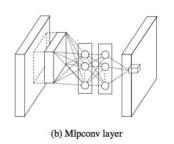
## 5. Another Net



#### ✓ Network in Network (NiN)

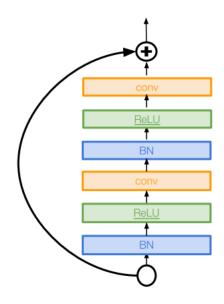
- -Mipconv layer로 구성된 Micronetwork
- -Multilayer Perceptron을 이용
- -GoogLeNet보다 먼저 Bottleneck 아이디어 제시





#### Identity Mapping in Deep Residual Network

- -ResNet Block Design 보완
- -ResNet의 Block Path를 조절하여 Direct path를 증가시킴
- -정보 전달/Backprop 성능 향상

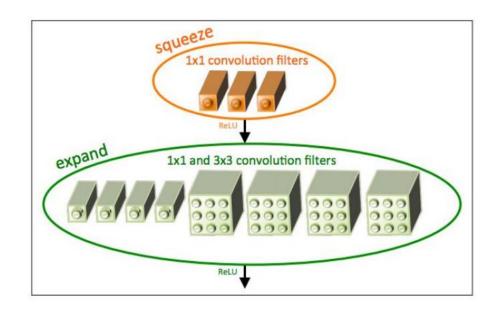


## 5. Another Net



#### ✓ SqueezeNet

-Squeeze layer에서 시작해 expand layer로 전달 -AlexNet과 유사한 정확도, 50배 적은 parameter, 510배 작은 size

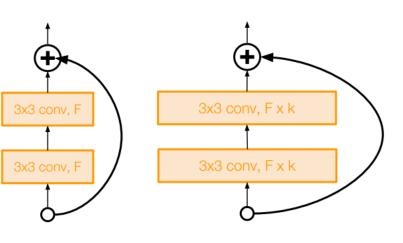


## 5. Another Net



#### ✓ Wide Residual Network <improve>

- -Residual이 Depth보다 중요하다는 관점
- -Residual Block 크기 확장 (Filter 개수 ↑)
- -기존 152개 Layer보다 50 Layer의 Wide Residual Network 성능이 좋음을 확인 (계산 효율의 증가)

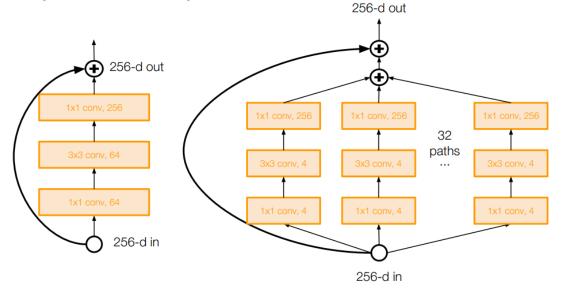


Basic residual block

Wide residual block

#### ResNeXt <improve>

- -ResNet에 multiple parallel pathways 추가
- -inception Module 방식과 유사



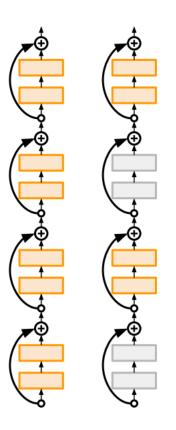




#### ✓ Deep Networks with Stochastic

Depth <improve>

- -Network가 깊어질수록 gradient가 사라지는 문제
- -Train time의Network 일부를 identity connection 으로 변환
- -Dropout과 유사

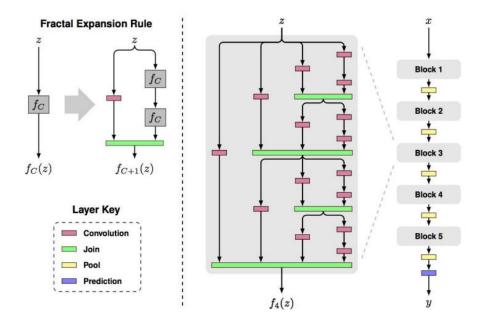






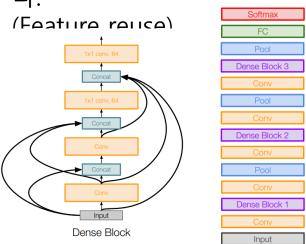
#### ✓ FractalNet <Beyond>

- -Residual connection과 shallow-deep 정보전달이 무의미하다는 관점
- -shallow, deep 정보 모두 원활하게 전달하고자 함 -프랙탈 형태의 network



#### ✓ Densely Connected Convolutional Network <beyond>

- -Dense block으로 각 layer를 다른 모든 layer에 연결
- -Network의 입력 이미지=모든 Network 입력+아래 network 출력
- -Feature를 모두 전달되므로 잘 사용될 수 있다.







# 감사합니다.